

EDA 실습 문제지 (초안)

1. 실습 목적

- 데이터 전처리, 결측치 처리, 이상치 처리의 필요성을 전/후 비교로 이해한다.
- 시각화 결과를 근거로 분석 결론을 작성한다.

2. 실습 데이터

- 기본 파일: `data/raw\_dirty.csv`
- 비교 파일(선택): `data/raw\_clean.csv`
- 주요 타겟: `Rented Bike Count`

3. 과제 문항

Q1. 데이터 스키마 점검 + 분포 진단

- 변수 타입, 행/열 수, 기초 통계량을 정리한다.
- 타겟 변수의 skewness, kurtosis를 보고하고 Q-Q plot을 그린다.
- 정규성 검정(Shapiro-Wilk)을 수행하여 후속 검정 방법 선택의 근거를 마련한다.

Q2. 중복 및 타입 오류 점검

- 중복 행, 날짜 파싱 오류, 비정상 범주를 점검하고 수정한다.
- ****주의****: 이 단계를 먼저 처리해야 이후 결측치/이상치 분석이 올바르게 작동합니다.
- ****힌트****: 범주형 변수의 `value\_counts()`를 확인하여 표기 불일치가 있는지 살펴보세요.

Q3. 결측치 진단

- 변수별 결측 비율을 계산하고 결측 패턴을 시각화한다.

Q4. 결측치 처리 전략 비교

- `drop` 과 `group\_median` 을 각각 적용하고 전/후 차이를 비교한다.
- ****주의****: drop 적용 시 손실 행 수와 손실 비율을 반드시 보고한다.
- ****가설 검정****: 처리 전/후 분포 차이에 대해 통계 검정(t-test 또는 Mann-Whitney U)을 수행한다.
- ****효과 크기****: Cohen's d를 함께 보고한다.

Q5. 이상치 탐지

아래 두 단계로 이상치 후보를 식별한다.

1. ****도메인 규칙 확인****: 물리적으로 불가능한 값이 있는가? (예: 대여 수 < 0, 강수량 < 0)

2. ****통계 기준 적용****: IQR 또는 Z-score로 극단값 식별

- 필수 결과: 박스플롯 + 도메인 규칙 위반 건수 표

Q6. 이상치 처리 전략 비교

- `remove`와 `cap`을 각각 적용하고 통계량 변화를 비교한다.
- 가설 검정 + Cohen's d를 함께 보고한다.

Q7. 파생 변수 생성

- 시간대, 주말/평일, 계절 등 파생 변수를 생성한다.

Q8. 핵심 질문 1

- 질문: 수요 피크 시간은 언제인가?
- 처리 전/후 결과를 같은 축으로 비교한다.

Q9. 핵심 질문 2

- 질문: 날씨와 수요의 관계는 어떤가?
- 상관/산점도 기반으로 해석하며, 각 상관계수에 p-value를 함께 보고한다.

Q10. 결론

- 인사이트 3개, 운영 제안 1개, 한계 2개를 작성한다.

4. 제출물

1. 분석 노트북 1개
2. 요약 보고서 1개(2~4페이지)
3. 비교 시각화 6개 이상

5. 필수 작성 규칙

1. 전/후 비교 그래프는 같은 축 범위를 사용한다.
2. 아래 지표를 숫자로 반드시 보고한다.
 - 행 수 변화
 - 결측률 변화
 - 평균/중앙값 변화
 - IQR(또는 표준편차) 변화
1. 전/후 비교에는 가설 검정(p-value)과 효과 크기(Cohen's d)를 함께 보고한다.
2. 상관계수에는 유의성(p-value)을 함께 표기한다.