

EDA 답안 가이드 (초안)

1. 답안 작성 원칙

1. 코드보다 의사결정 근거를 우선 설명한다.
2. 전처리 전/후를 같은 질문과 같은 축으로 비교한다.
3. 결론은 정량 수치와 함께 작성한다.

2. 문항별 답안 방향

Q1 데이터 스키마 점검 + 분포 진단

- 스키마 표, 기초 통계량을 우선 제시한다.
- 타깃 변수의 skewness, kurtosis, Q-Q plot을 보고한다.
- Shapiro-Wilk 정규성 검정을 수행하고 결과에 따라 Q4/Q6 검정 방법을 선택한다.

Q2 중복/타입 오류 점검

- 중복 건수, 날짜 파싱 오류, 범주형 표기 불일치를 찾아 수정한다.
- ****체크포인트****: 이 단계를 먼저 처리해야 Q3 이후 결과가 올바름.
- 수정 전/후 레코드 예시를 최소 1개 제시한다.

Q3 결측치 진단

- 결측 비율 표 + 결측 패턴 시각화를 함께 제시한다.
- 결측이 특정 시간대/범주에 몰려 있는지 확인한다.

Q4 결측치 처리 전략 비교

- `drop` 과 `group\_median` 을 둘 다 시도한다.
- ****체크포인트****: drop 시 손실이 예상보다 클 수 있음 — Date 컬럼 결측이 다른 결측과 겹치기 때문.
- 표본 손실률과 분포 왜곡을 비교해 최종 전략을 선택한다.
- ****가설 검정****: 처리 전/후 분포 차이에 대해 Mann-Whitney U(비정규) 또는 t-test(정규)를 수행한다.
- ****효과 크기****: Cohen's d를 보고하여 실질적 차이 크기를 평가한다.

Q5-Q6 이상치 처리

- ****먼저 도메인 규칙 위반 값을 확인한다**** (예: 대여량 < 0, 강수량 < 0 = 물리적 불가능 값).
- IQR 기준 탐지 근거를 명시한다.
- `remove` 와 `cap` 결과의 평균/중앙값/IQR 변화를 비교한다.
- 가설 검정 + Cohen's d를 함께 보고한다.
- 희귀 이벤트 보존 필요성을 함께 논의한다.

Q7 파생 변수

- 시간대 구간, 주말/평일, 계절 변수를 만든다.
- 파생 변수로 설명력이 올라가는지 그래프로 확인한다.

Q8-Q9 핵심 질문 분석

- 질문 1: 수요 피크 시간
- 질문 2: 날씨와 수요 관계
- 두 질문 모두 전/후 오버레이 그래프와 정량 비교를 포함한다.
- Q9에서 각 상관계수에 p-value를 함께 보고하고 유의성을 표기한다.

Q10 결론

- 인사이트 3개, 운영 제안 1개, 분석 한계 2개를 제시한다.

3. 모범 답안 문장 템플릿

1. 사실: 어떤 패턴이 관측되었다.
2. 근거: 전/후 비교에서 어떤 수치가 어떻게 변했다.
3. 제안: 운영상 어떤 행동을 권장한다.

4. 자주 발생하는 오류

1. 중복/타입 오류를 나중에 처리하여 이미 오염된 결과로 분석 진행
2. 결측치 제거만 수행하고 손실률을 보고하지 않음
3. 도메인 규칙 확인 없이 IQR만 적용하여 물리적 불가능 값을 놓침
4. 이상치 임계값을 근거 없이 임의 설정
5. 그래프 축을 다르게 써서 차이를 과장
6. 인사이트에 실행 제안이 없음
7. 정규성 검정 없이 t-test를 적용하여 잘못된 검정 결과 도출
8. p-value만 보고 효과 크기를 무시하여 실질적 의미를 간과
9. 상관계수를 보고하면서 유의성(p-value)을 함께 제시하지 않음